



SIPANJI: Integrasi *Multi-Sensor Satellite Data* dan *Adaptive Artificial Intelligence* untuk Prediksi, Pemantauan, dan Perencanaan Mitigasi Banjir secara *Real-Time* di Jabodetabek



Nomor Peserta

ASEC013

Nama Ketua

DAFFA ELGO SANTOSA

Anggota kedua

I MADE TELAGA DWIRADITYA

**AIRLANGGA STATISTICS EVENT
UNIVERSITAS AIRLANGGA
2025**



Sumber Data

Data/Variabel	Link/Tautan Sumber
DEM*	COPERNICUS/DEM/GLO30
<i>Elevation**</i>	diambil dari DEM
<i>SlopeDegree**</i>	
<i>AspectDegree**</i>	
<i>CurvatureAll**</i>	
TWI**	
SPI**	
<i>Flowacc*</i>	WWF/HydroSHEDS/15ACC
<i>WorldCover</i> <i>2020*</i>	ESA/WorldCover/v200
NDVI*	MODIS/061/MOD13Q1
<i>Rain mm total*</i>	NASA/GPM_L3/IMERG_V07
MNDWI*	COPERNICUS/S2_SR
<i>FloodMask*</i>	COPERNICUS/S1_GRD
Kepadatan Penduduk (Jiwa/km ²)	BPS Provinsi DKI Jakarta, BPS Provinsi Jawa Barat, BPS Provinsi Banten

Catatan

*) Data diambil langsung melalui platform *Google Earth Engine*

**) Data diolah melalui platform *Google Earth Engine*

ASEC
AIRLANGGA STATISTICS ESSAY COMPETITION

1. Pendahuluan

1.1 Latar Belakang

Banjir merupakan bencana alam yang paling sering terjadi di Indonesia, khususnya di wilayah metropolitan Jakarta, Bogor, Depok, Tangerang, dan Bekasi (Jabodetabek). Sebagai pusat pemerintahan dan ekonomi nasional, banjir di kawasan ini berdampak besar pada sosial dan ekonomi. Wilayah utara Jabodetabek yang berupa dataran rendah rawan genangan, sementara selatan dan barat sebagai hulu sungai besar seperti Ciliwung dan Pesanggrahan menyumbang aliran air yang memicu banjir. Risiko ini semakin tinggi akibat urbanisasi, penurunan muka tanah, dan perubahan iklim (Tehrany et al., 2019).

Sepanjang 2024, banjir terjadi hampir setiap bulan. Awal Januari, 24 RT di Jakarta Selatan terendam hingga 1,2 meter, dan pada akhir November luapan Kali Ciliwung menyebabkan genangan 2,6 meter di Kampung Melayu dan Rawajati, memaksa ratusan warga mengungsi. BPBD DKI Jakarta mencatat 1.810 kejadian bencana, termasuk banjir, dengan 10.632 pengungsi dan 87 korban jiwa, menunjukkan masalah yang mendesak untuk ditangani. Untuk itu, dibutuhkan sistem deteksi real-time berbasis remote sensing seperti *Sentinel-1* dan GPM (Chen et al., 2020), serta prediksi berbasis *machine learning* yang mempertimbangkan faktor seperti curah hujan, NDVI, elevasi dan kemiringan. Penelitian sebelumnya menunjukkan elevasi dan kemiringan sebagai faktor utama risiko banjir, diikuti jarak ke sungai dan tata guna lahan (Farhadi & Najafzadeh, 2023)


1.2 Identifikasi Masalah

Banjir di Jabodetabek terus berulang dengan dampak besar, mulai dari kerusakan infrastruktur, pengungsian ribuan warga, hingga lumpuhnya aktivitas ekonomi seperti yang sering diberitakan media. Sistem deteksi yang ada belum mampu memberikan informasi real-time dan akurat, sehingga respons tanggap darurat sering terlambat. Selain itu, prediksi banjir yang tersedia masih sederhana karena hanya berbasis data curah hujan tanpa memperhitungkan faktor lingkungan seperti perubahan tata guna lahan dan elevasi (Farhadi & Najafzadeh, 2023). Minimnya analisis komprehensif mengenai faktor penyebab banjir juga menghambat pemerintah dalam merumuskan kebijakan mitigasi yang tepat sasaran (Chen et al., 2020).

2. Pembahasan

2.1 Metode Analisis

Tahapan-tahapan analisis yang dilakukan dalam penelitian ini adalah sebagai berikut.





2.1.1 Data Preprocessing

Tahap pra-pemrosesan data dilakukan melalui dua langkah utama, yaitu pemetaan banjir menggunakan citra *Sentinel-1* dan identifikasi badan air permanen menggunakan citra *Sentinel-2*. Dari *Sentinel-1*, diperoleh 44 citra komposit dua mingguan (1 Januari 2024–7 September 2025) yang diolah dengan metode *Otsu thresholding* untuk memisahkan area tergenang dari area kering (Aldiansyah et al., 2024). Sementara itu, citra *Sentinel-2* pada musim kemarau (Juli–September 2024) digunakan untuk menghitung *Modified Normalized Difference Water Index* (MNDWI) guna memetakan sungai, waduk, dan danau permanen. Selanjutnya, hasil pemetaan banjir dikurangi dengan data badan air permanen sehingga diperoleh 44 peta banjir murni yang kemudian digunakan sebagai variabel dependen (Y) dalam analisis.

Fitur pada variabel prediktor diseragamkan ukurannya agar memiliki resolusi dan satuan yang konsisten. Data prediktor dihimpun dalam interval dua mingguan, sejalan dengan periode pemetaan banjir, sehingga diperlukan penyesuaian temporal seperti pengelompokan dan *time window alignment*. Data *MODIS* yang memiliki resolusi temporal berbeda diperlakukan khusus melalui interpolasi atau agregasi. Setelah seluruh data selaras, dilakukan *scaling* untuk menormalkan nilai tiap variabel agar berada pada rentang yang sama. Langkah ini penting untuk mencegah bias akibat perbedaan skala, sehingga setiap fitur dapat berkontribusi seimbang dalam proses pelatihan dan meningkatkan akurasi prediksi.

ASEC
AIRLANGGA STATISTICS ESSAY COMPETITION

2.1.2 Modelling

Tahapan pemodelan dalam kajian ini mengacu pada pembangunan peta kerentanan banjir (*Flood Susceptibility Map/FSM*) berbasis *machine learning*. Pemodelan diformulasikan sebagai masalah klasifikasi biner dengan keluaran berupa nilai 1 (banjir) dan 0 (tidak banjir).

1. *Logistic Regression (LR)*.

Model ini dipilih karena sederhana dan mudah diinterpretasikan, meski kurang optimal untuk menangkap pola non-linear yang kompleks.

2. *Naïve Bayes (NB)*.

NB bekerja dengan prinsip teorema Bayes dan asumsi independensi antarvariabel. Model ini dikenal efisien dalam perhitungan probabilitas, meskipun sensitif terhadap korelasi antarvariabel prediktor.

3. *Random Forest (RF)*.

RF membangun banyak decision tree dari sampel acak menggunakan bagging dan pemilihan fitur acak, sehingga tahan *overfitting* dan efektif menangkap pola non-linear pada data kompleks seperti Jabodetabek.

4. *Gradient Boosting (GB)*.

GB merupakan metode *boosting* yang membangun model secara bertahap dengan meminimalkan fungsi kerugian melalui pendekatan *gradient descent*.

5. *Stochastic Gradient Boosting (SGB)*.

SGB adalah varian GB yang menambahkan unsur stokastik dengan mengambil sampel acak tiap iterasi, sehingga mengurangi *overfitting* dan meningkatkan generalisasi.

6. *Extreme Gradient Boosting (XGBoost)*.

XGBoost adalah model boosting berbasis *decision tree* yang melatih pohon secara berurutan untuk memperbaiki kesalahan sebelumnya, dikenal efisien, fleksibel, dan mampu mencegah *overfitting*.

7. **Light Gradient Boosting (LightGBM).**

LightGBM adalah algoritma *gradient boosting* yang lebih ringan dan cepat dibandingkan XGBoost, menggunakan *leaf-wise tree growth* dan optimasi memori, sehingga cocok untuk dataset besar.

8. **Extra Trees (ET)**


ET adalah algoritma ensemble mirip RF, namun menggunakan pemilihan *split* yang lebih acak, sehingga meningkatkan keragaman pohon dan mempercepat pelatihan.

9. **K-Nearest Neighbor (KNN)**

Metode KNN mengklasifikasikan lokasi berdasarkan mayoritas label dari tetangga terdekat dalam ruang fitur. Metode ini sederhana namun efektif, khususnya ketika data memiliki pola lokal yang mencerminkan kedekatan spasial.

10. **EfficientNetB0**


EfficientNetB0 adalah arsitektur CNN dengan compound scaling yang menyeimbangkan kedalaman, lebar, dan resolusi citra, sehingga mencapai akurasi tinggi dengan kebutuhan komputasi yang rendah.



11. **Xception**


Xception merupakan pengembangan arsitektur *Inception* yang mengganti konvolusi standar dengan *depthwise separable convolutions*,

membuat model lebih ringan namun mampu menangkap pola spasial kompleks.



12. DenseNet121

DenseNet121 memiliki koneksi langsung antar lapisan yang menjaga aliran informasi dan gradien, sehingga mengurangi vanishing gradient dan meningkatkan efisiensi parameter.



Data penelitian dibagi dengan *time series split* untuk menjaga kronologi, yaitu 48 minggu (1 Januari–2 Desember 2024) sebagai data latih dan 24 minggu berikutnya (2 Desember 2024–19 Mei 2025) sebagai data uji. Evaluasi kinerja model menggunakan *F1-Score*, *Precision*, *Recall*, dan *AUROC*, dengan *Training Time* sebagai ukuran efisiensi. *F1-Score* diprioritaskan karena mampu menyeimbangkan *Precision* dan *Recall*, sehingga menekan *false negative* maupun *false positive*. *AUROC* digunakan untuk menilai kemampuan membedakan area banjir dan tidak banjir, sedangkan *Training Time* memastikan model tetap praktis.


Analisis pascapemodelan dilakukan untuk memahami kontribusi variabel terhadap prediksi. *Feature importance* digunakan untuk mengukur pengaruh relatif tiap variabel, sementara SHAP (*Shapley Additive Explanations*) menjelaskan arah

serta besarnya pengaruh pada level individu. Dengan demikian, hasil prediksi tidak hanya akurat, tetapi juga transparan dan dapat dipertanggungjawabkan. Melalui perbandingan berbagai algoritma, penelitian ini bertujuan menemukan model andal untuk memetakan kerentanan banjir di Jabodetabek sekaligus mendukung kebijakan mitigasi dan tata ruang.


2.2 Hasil dan Pembahasan

2.2.1 Eksplorasi Data

Tahap awal analisis dilakukan melalui eksplorasi data spasial hasil pra-pemrosesan.



Gambar tersebut menampilkan tiga peta utama pembentuk variabel dependen (Y). Peta pertama (kiri) berupa *flood mask* dari citra *Sentinel-1* dengan metode *Otsu thresholding*, yang masih mencakup area banjir dan badan air permanen. Peta kedua (tengah) menunjukkan badan air permanen dari citra *Sentinel-2* pada musim kemarau 2024, seperti sungai, waduk, dan danau. Peta ketiga (kanan) merupakan hasil substraksi keduanya sehingga menghasilkan peta banjir murni. Dari ketiga peta terlihat bahwa genangan lebih banyak terkonsentrasi di pesisir utara Jakarta dan sekitar sungai besar, sementara badan air permanen tetap stabil pada alurnya. Hal ini menegaskan pentingnya pemisahan badan air permanen agar identifikasi banjir lebih akurat.



Berdasarkan eksplorasi data awal periode 01–15 Januari 2024, banjir di Jabodetabek dipengaruhi oleh empat faktor utama: topografi, hidrologi, tutupan lahan dan vegetasi, serta curah hujan. Bagian utara yang datar dan rendah cenderung menjadi pusat genangan, sedangkan bagian selatan yang lebih tinggi berperan sebagai hulu aliran air. Variabel hidrologi seperti TWI, SPI, dan *Flow Direction* menunjukkan mekanisme akumulasi dan pergerakan air dari selatan ke utara. Area urban dengan tutupan vegetasi rendah memiliki infiltrasi yang buruk, sehingga

limpasan permukaan meningkat, khususnya saat curah hujan tinggi seperti di periode ini. Secara keseluruhan, interaksi keempat faktor ini menjadi dasar penting dalam model prediktif untuk memetakan area rawan banjir dan mendukung strategi mitigasi berbasis data.


2.2.2 Hasil Analisis

Setelah dilakukan proses *preprocessing* untuk setiap data gambar yang ada, selanjutnya adalah untuk memasukkan data *train* dan data *test* kedalam model yang dibentuk.


2.2.2.1 Evaluation

<i>Model</i>	<i>F1-Score</i>	<i>Precision</i>	<i>Recall</i>	<i>AUROC</i>	<i>Training Time (s)</i>
RF	0.6823	0.6934	0.6716	0.848	1507.5372
SGB	0.6808	0.7094	0.6544	0.8595	152.9798
XGBoost	0.6799	0.7156	0.6477	0.8615	87.6071
GB	0.6782	0.7096	0.6495	0.8564	4329.6657
LightGBM	0.6741	0.7141	0.6384	0.8593	88.7866
KNN	0.6552	0.6719	0.6393	0.8309	27.8244
NB	0.3406	0.4518	0.2734	0.6316	1.2298
LR	0.2063	0.5739	0.1258	0.6938	12.66
ET	0.1628	0.7407	0.0915	0.811	357.0688
<i>EfficientNetB0</i>	0.2602	0.1521	0.8993	0.6147	227.8836
<i>Xception</i>	0.2278	0.1307	0.8874	0.5422	443.8733
<i>DenseNet121</i>	0.2236	0.1731	0.3156	0.6767	369.701

AIRLANGGA STATISTICS ESSAY COMPETITION




Berdasarkan hasil analisis di atas, terlihat bahwa model terbaik dalam penelitian ini adalah *Random Forest* dengan *F1-Score* tertinggi diantara semua model lainnya. Sehingga model ini yang akan digunakan sebagai analisis prediktif.




Berdasarkan *confusion matrix*, terlihat bahwa hanya sebagian kecil *grid* yang salah diprediksi, yang ditandai dengan area berwarna putih pada diagonal yang salah. Hal ini menunjukkan bahwa kinerja model sudah baik dalam memprediksi data.

2.2.2.2 Post Analysis



Berdasarkan grafik *Feature Importance* dari model *Random Forest*, terlihat bahwa variabel *World Cover* memiliki pengaruh paling dominan terhadap prediksi banjir. Hal ini menunjukkan bahwa jenis tutupan lahan sangat menentukan risiko banjir. Area dengan dominasi lahan terbangun seperti permukiman padat cenderung memiliki risiko lebih tinggi karena rendahnya kemampuan infiltrasi air. Oleh karena itu, pemerintah perlu memperkuat kebijakan tata ruang dengan membatasi alih fungsi lahan hijau menjadi area terbangun dan memperluas ruang terbuka hijau untuk meningkatkan kapasitas resapan air.


Faktor berikutnya adalah *elevation* (0.195) yang menunjukkan pentingnya topografi, di mana dataran rendah lebih rentan tergenang. Untuk itu, pembangunan sistem drainase. *Aspect Degree* dan *Slope Degree* juga signifikan, mengindikasikan bahwa arah dan kemiringan lereng memengaruhi aliran air. Pemerintah dapat memanfaatkan informasi ini untuk perencanaan kanal dan saluran air agar aliran dapat diarahkan dengan optimal. Selain itu, NDVI sebagai indikator vegetasi juga berperan penting. Daerah dengan tutupan vegetasi tinggi dapat mengurangi risiko banjir, sehingga program reboisasi dan penghijauan perkotaan menjadi langkah strategis yang perlu ditingkatkan.



Grafik SHAP Value menunjukkan arah pengaruh tiap variabel terhadap prediksi banjir. NDVI dengan nilai rendah cenderung berhubungan dengan risiko banjir yang lebih kecil, sedangkan nilai tinggi (merah muda) justru meningkatkan peluang banjir karena menunjukkan area rawa atau lahan selalu basah. Nilai sedang (ungu) bersifat netral. Pada *elevation*, nilai rendah (biru) menunjukkan dataran rendah yang lebih rawan banjir, sementara nilai tinggi (merah muda) menunjukkan area perbukitan yang lebih aman. Temuan ini dapat dimanfaatkan dalam *early warning system*, misalnya dengan memprioritaskan wilayah yang memiliki kombinasi NDVI tinggi dan elevasi rendah sebagai area dengan risiko banjir lebih besar, sehingga pemerintah dapat mengarahkan mitigasi seperti pembangunan tanggul, sistem peringatan dini, atau evakuasi lebih efektif.

ASEC
AIRLANGGA STATISTICS ESSAY COMPETITION

2.2.2.3 Hasil Segmentasi Prediksi



Peta prediksi banjir dari model Random Forest untuk periode 2–16 Desember 2024 menunjukkan area yang berpotensi banjir ditandai dengan warna biru, sedangkan area yang diprediksi tidak mengalami banjir ditandai dengan warna abu-abu. Berdasarkan plot ini, wilayah pesisir utara Jakarta tampak memiliki risiko banjir paling tinggi, khususnya di sekitar Muara Angke, Pluit, Penjaringan, hingga ke kawasan pesisir di Kabupaten Bekasi dan Kabupaten Tangerang. Area biru yang padat di wilayah tersebut menggambarkan daerah dataran rendah dengan drainase yang buruk serta sering terdampak banjir rob. Selain pesisir, terdapat juga beberapa sebaran kecil area biru di bagian tengah dan selatan, yang menunjukkan banjir lokal di daerah sekitar aliran sungai dan area perbukitan, misalnya di sebagian wilayah Bogor dan Depok.


Hasil ini konsisten dengan laporan banjir pada periode tersebut. Pada 16 Desember 2024, dilaporkan banjir rob yang menggenangi pesisir Jakarta Utara termasuk Muara Angke, Pelabuhan Sunda Kelapa, kawasan Ancol, Kapuk Muara, dan jalan RE Martadinata, dengan ketinggian air mencapai 30–90 cm di tiga RT di Muara Angke. Selain itu, pada 8 Desember 2024, tiga RT di Kelurahan Joglo, Jakarta Barat terendam banjir akibat hujan deras dengan ketinggian 40–70 cm. Hal

ini memperkuat temuan model bahwa area pesisir utara memiliki risiko banjir yang paling tinggi, sementara daerah perkotaan di bagian barat dan titik-titik lokal lainnya juga rentan mengalami genangan ketika terjadi hujan ekstrem.

2.3 Dashboard

Sebagai bentuk implementasi hasil pemodelan, penelitian ini mengembangkan sebuah sistem berbasis *dashboard* bernama SIPANJI (Sistem Pantauan Banjir Terintegrasi). *Dashboard* ini dirancang dalam dua format tampilan, yakni versi PC yang diperuntukkan bagi badan yang berwenang atau pemerintah, serta versi HP yang ditujukan untuk masyarakat umum. Perbedaan format ini dimaksudkan agar setiap kelompok pengguna memperoleh informasi sesuai dengan kebutuhan dan tingkat kewenangannya.


2.3.1 Tampilan PC



Tampilan PC dirancang komprehensif untuk mendukung pengambilan keputusan. Fitur utama meliputi pemilihan tanggal (real-time untuk hari ini dan hari-hari sebelumnya, serta *forecast* untuk hari-hari berikutnya) dan juga pemilihan wilayah di Jabodetabek di mana area yang tidak dipilih ditampilkan berwarna abu-abu. Informasi 'Total Area Terdampak' ditampilkan berdasarkan luasan area biru, sedangkan 'Total Populasi Terdampak' dihitung berdasarkan kepadatan penduduk per km².

Selain itu, terdapat tombol ‘Posko Pengungsian’, di mana posko di luar area banjir ditampilkan jelas, sedangkan posko dalam area banjir divisualisasikan secara lebih transparan. Fitur ‘Kontak Darurat’ juga disediakan untuk menghubungkan langsung dengan pihak berwenang. Terakhir, bagian ‘Faktor Pengaruh’ menampilkan kontribusi variabel dominan berdasarkan analisis *feature importance* dari model terbaik, sehingga pemerintah dapat memahami penyebab utama banjir yang terjadi saat itu.

2.3.2 Tampilan HP



Tampilan HP dibuat lebih sederhana untuk memudahkan masyarakat. Fitur yang tersedia meliputi pemilihan tanggal, pemilihan wilayah, informasi area terdampak, posko pengungsian, serta kontak darurat. Berbeda dengan versi PC, tampilan ini tidak menampilkan populasi terdampak maupun faktor pengaruh karena fokusnya pada pemantauan kondisi dan kebutuhan lapangan.

Dengan dua format ini, SIPANJI dapat memberikan informasi sesuai kebutuhan pengguna: ringkas dan praktis bagi masyarakat, serta komprehensif bagi pemerintah dalam mitigasi banjir Jabodetabek.

3. Kesimpulan dan Saran

3.1 Kesimpulan

Penelitian ini menunjukkan bahwa pemodelan kerentanan banjir di wilayah Jabodetabek dengan pendekatan *machine learning* dapat memberikan hasil yang akurat dan dapat diandalkan. Dari serangkaian algoritma yang diuji, *Random Forest* terbukti menjadi model terbaik dengan nilai *F1-Score* tertinggi. Analisis lebih lanjut melalui *feature importance* dan *SHAP value* mengungkapkan bahwa faktor tutupan lahan (*World Cover 2020*), elevasi, aspek lereng, kemiringan, serta vegetasi (NDVI) merupakan variabel paling berpengaruh dalam menentukan risiko banjir.

Hasil pemetaan prediksi memperlihatkan bahwa wilayah pesisir utara Jakarta, khususnya Muara Angke, Pluit, dan Penjaringan, menjadi daerah dengan tingkat kerawanan banjir paling tinggi. Selain itu, beberapa titik di wilayah tengah dan selatan Jabodetabek juga rawan genangan lokal akibat curah hujan tinggi maupun keterbatasan sistem drainase.

Sebagai implementasi, pengembangan dashboard SIPANJI (Sistem Pantauan Banjir Terintegrasi) diharapkan mampu menyajikan informasi sesuai kebutuhan pengguna. Versi PC menyediakan data komprehensif bagi pemerintah dalam mendukung pengambilan keputusan, sementara versi HP memberikan informasi yang lebih sederhana dan mudah diakses masyarakat.

3.2 Saran

Pemerintah dapat memanfaatkan hasil pemodelan ini untuk merumuskan kebijakan mitigasi banjir melalui pengendalian tata ruang, penambahan ruang terbuka hijau, serta penguatan drainase dan pompa air di wilayah berisiko tinggi. Dashboard SIPANJI perlu diintegrasikan dengan sistem peringatan dini untuk mempercepat respons tanggap darurat, sementara masyarakat dapat memantau kondisi banjir dan lokasi evakuasi melalui versi *mobile*. Penelitian selanjutnya disarankan menggunakan data beresolusi lebih tinggi dan menambahkan variabel sosial-ekonomi agar analisis risiko banjir lebih komprehensif.



4. Daftar Pustaka


- Aldiansyah, R., Wibowo, A., & Prasetyo, Y. (2024). Utilization of Otsu thresholding method for automatic flood inundation mapping using Sentinel-1 imagery. *Journal of Geospatial Remote Sensing*, 5(2), 1522–1534.
- Aldiansyah, S., Saputra, R. A., Wahid, K. A., Madani, I., & Ningsih, D. S. W. (2024). Rapid Flood Inundation Mapping Using Multi-Temporal Sentinel-1 SAR: An Example from Kendari City. *Jurnal Geosains Dan Remote Sensing*, 5(1), 15-26.
- BPBD DKI Jakarta. (2024). *Laporan kejadian bencana DKI Jakarta tahun 2024*. Badan Penanggulangan Bencana Daerah DKI Jakarta. Diakses dari
- Chen, W., Li, W., Chen, G., Liu, C., Zhang, S., & Qi, X. (2020). *Comprehensive flood risk assessment based on multi-source remote sensing data and machine learning models: A case study of Zhengzhou, China*. *Remote Sensing*, 12(24), 4077.
- Farhadi, H., & Najafzadeh, M. (2023). *Application of machine learning algorithms for flood susceptibility mapping in urban areas*. *Journal of Hydrology*, 618, 129151.
- S, S., Geetha, P. & Madhu, D. Flood Susceptibility Map of Periyar River Basin Using Geo-spatial Technology and Machine Learning Approach. *Remote Sens Earth Syst Sci* 8, 1–21 (2025). <https://doi.org/10.1007/s41976-024-00101-7>
- Subbarayan, Saravanan & Devanantham, Abijith & Masthan Reddy, Nagireddy & K S S, Parthasarathy & Janardhanam, Niraimathi & Subbarayan, Sathiyamurthi & Vivek, Sivakumar. (2023). Flood susceptibility mapping using machine learning boosting algorithms techniques in Idukki district of Kerala India. *Urban Climate*. 49. 101503. 10.1016/j.uclim.2023.101503.
- Tallar, R., Muthusamy, M., & Jain, S. (2022). *Urban flood hazard mapping using remote sensing and multi-criteria analysis: A case study*. *Natural Hazards*, 111, 1275–1293.



Tehrany, M. S., Pradhan, B., Jebur, M. N., & Shafri, H. Z. M. (2019). *Flood susceptibility mapping using a novel ensemble weights-of-evidence and support vector machine models in GIS. Journal of Hydrology*, 569, 159–172.





Tepetidis, N., Benekos, I., Iliopoulou, T., Dimitriadis, P., & Koutsoyiannis, D. (2025). Combining Machine Learning Models and Satellite Data of an Extreme Flood Event for Flood Susceptibility Mapping. *Water*, 17(18), 2678. <https://doi.org/10.3390/w17182678>





Wahba, M., Sharaan, M., Elsadek, W.M. *et al.* Examination of the efficacy of machine learning approaches in the generation of flood susceptibility maps. *Environ Earth Sci* 83, 429 (2024).







5. Lampiran


Eksplorasi Data Variabel Target (Y) untuk Setiap Periode









Peta Sebaran Air Periode 01/07/2024 - 14/07/2024




Peta Sebaran Air Periode 15/07/2024 - 28/07/2024











Peta Sebaran Air Periode 29/07/2024 - 11/08/2024











Peta Sebaran Air Periode 12/08/2024 - 25/08/2024




































ASEC
AIRLANGGA STATISTICS ESSAY COMPETITION



Eksplorasi Data Variabel Prediktor (*feature/X*) untuk Setiap Periode






































AIRLANGGA STATISTICS ESSAY COMPETITION

Hasil Prediksi Fenomena Banjir pada Data *Test*

