


WASPADA-API: SISTEM PREDIKSI RISIKO KARHUTLA BERBASIS TWO-STAGE XGBOOST-BAYESIAN INLA UNTUK MITIGASI KABUT ASAP LINTAS BATAS ASEAN

Subtema: Lingkungan Hidup dan Dinamika Digital



Disusun oleh:

Andalan Raihad Nobelim (24/538031/PA/22817, 2024)

Mutia Nurbaiti Azzahra (24/539612/PA/22913, 2024)

UNIVERSITAS GADJAH MADA

TAHUN 2026



1. PENDAHULUAN

Pencemaran kabut asap lintas batas atau *transboundary haze pollution* merupakan pencemaran udara ketika asap dari kebakaran hutan dan/atau lahan di suatu negara menyebar hingga melintasi batas negara lain (ASEAN, 2002). Di Asia Tenggara, persoalan ini tidak hanya berdampak pada kualitas lingkungan, tetapi juga mengganggu kesehatan masyarakat, mobilitas, aktivitas ekonomi, dan hubungan tata kelola lintas negara. ASEAN telah merespons isu ini melalui ASEAN Agreement on Transboundary Haze Pollution sejak 2002 untuk mencegah dan memantau kabut asap lintas batas melalui upaya nasional serta kerja sama regional (ASEAN, 2002). Namun, berulangnya kejadian kabut asap menunjukkan bahwa tantangan utama tidak hanya terletak pada keberadaan kerja sama, tetapi juga pada efektivitas pencegahan dini di wilayah sumber.

Urgensi persoalan ini terlihat jelas pada kawasan maritim Asia Tenggara, terutama ketika kebakaran hutan dan lahan di Indonesia berkembang menjadi kabut asap lintas batas. Krisis karhutla Indonesia tahun 2015 menjadi salah satu kasus paling serius. Kebakaran pada tahun tersebut membakar sekitar 2,6 juta hektare lahan dan menimbulkan kerugian ekonomi sekitar Rp221 triliun atau US\$16,1 miliar bagi Indonesia (World Bank, 2016). Dampaknya tidak berhenti pada wilayah nasional karena kabut asap juga dikaitkan dengan gangguan kesehatan, penutupan sekolah dan bisnis, serta terganggunya transportasi di Indonesia, Malaysia, dan Singapura (Koplitz et al., 2016). Risiko serupa belum sepenuhnya hilang. Pada Juli 2025, ASEAN Specialised Meteorological Centre (ASMC) mengaktifkan Alert Level 2 untuk kawasan ASEAN bagian selatan akibat meningkatnya hotspot dan asap di Sumatra serta Kalimantan, dengan risiko kabut asap lintas batas menuju Semenanjung Malaysia dan Sarawak (ASMC, 2025).

Rangkaian tersebut menunjukkan bahwa pengendalian kabut asap lintas batas tidak cukup dilakukan setelah kebakaran meluas dan asap bergerak ke negara tetangga. Upaya mitigasi perlu diarahkan lebih awal pada wilayah sumber, terutama ketika titik panas mulai meningkat di kawasan rawan seperti Sumatra dan Kalimantan. Indonesia telah memiliki sistem pemantauan berbasis satelit, seperti SiPongi KLHK dan Citra Polar Hotspot BMKG yang memanfaatkan sensor VIIRS dan MODIS untuk mendeteksi titik panas (KLHK, 2026; BMKG, 2026). Namun, hotspot pada dasarnya hanya menunjukkan indikasi anomali panas, bukan tingkat risiko dampak kebakaran. Titik panas belum otomatis menjelaskan apakah kebakaran terjadi di gambut kering, berpotensi menghasilkan asap pekat, meluas dengan cepat, atau terbawa angin menuju negara tetangga. Selain itu, sistem yang ada belum dilengkapi prediksi risiko ke depan. Pemantauan berbasis satelit hanya menangkap kondisi yang sudah terjadi, bukan ancaman dalam beberapa bulan mendatang. Padahal, ketika hotspot muncul di banyak wilayah secara bersamaan atau diperkirakan meningkat menjelang musim



kering, pemerintah membutuhkan dasar prioritas berbasis risiko, seperti wilayah mana yang harus lebih dahulu dipatroli, dibasahi, atau dipadamkan.

Berdasarkan kebutuhan tersebut, penelitian ini menawarkan sistem prioritas risiko karhutla berbasis kombinasi XGBoost dan Bayesian hierarchical. Pendekatan ini memodelkan hubungan hotspot dengan faktor pemicu seperti curah hujan, suhu, kelembapan, angin, dan riwayat hotspot dengan mempertimbangkan variasi spasial dan temporal. Hasil analisis tidak berhenti pada pemantauan titik panas, tetapi menghasilkan forecast probabilistik per kabupaten lengkap dengan rentang ketidakpastian, peta risiko, dan pemecahan sumber risiko sebagai dasar prioritas mitigasi. Seluruh hasil disajikan melalui dashboard interaktif WaspadaApi yang dapat diakses publik dan pembuat kebijakan. Dalam konteks Asia Tenggara, pengendalian dini di wilayah sumber karhutla Indonesia menjadi strategi penting untuk menekan risiko kabut asap lintas batas dan mendukung ekosistem regional yang lebih layak huni, terintegrasi, dan berkelanjutan.

2. PEMBAHASAN

2.1 Metode Analisis

Analisis dilakukan melalui 4 tahap utama sebagaimana gambar 1.



Gambar 1. Diagram Alir Analisis

Langkah-langkah analisis yang dilakukan untuk tiap tahap akan dijelaskan berikutnya.

2.1.1 Pengumpulan Data

Pengumpulan data dilakukan untuk membangun model prediksi risiko kebakaran hutan dan lahan berbasis spasial-temporal di Indonesia. Data yang digunakan mencakup kejadian hotspot sebagai representasi aktivitas kebakaran dan variabel iklim harian sebagai faktor prediktor. Cakupan penelitian dibatasi pada wilayah Indonesia selama periode 2021–2025 agar model dapat merepresentasikan pola risiko terkini dan relevan untuk pengembangan sistem peringatan dini.

Data hotspot diperoleh dari Fire Information for Resource Management System (FIRMS) berbasis sensor VIIRS Suomi-NPP dengan resolusi 375 meter. Data ini digunakan untuk membentuk variabel target berupa jumlah hotspot aktual. Data curah hujan diperoleh dari Climate Hazards Group InfraRed Precipitation with Station (CHIRPS), sedangkan data suhu udara, suhu titik embun, dan komponen angin diperoleh dari produk reanalisis ERA5-Land yang dikembangkan oleh European Centre for Medium-Range Weather Forecasts

(ECMWF). Variabel iklim tersebut digunakan sebagai prediktor karena berkaitan dengan kondisi kering, kelembapan bahan bakar, dan potensi penyebaran api. Berikut adalah daftar variabel utama yang digunakan pada analisis ini.

Dataset FIRMS (Titik Api)	
latitude	Koordinat lintang pusat piksel deteksi api berukuran sekitar 375×375 m
longitude	Koordinat bujur pusat piksel deteksi api berukuran sekitar 375×375 m
date	Tanggal deteksi oleh satelit (UTC+00:00)
confidence	Tingkat kepercayaan deteksi (low/nominal/high)
frp	Fire Radiative Power; intensitas api (MW)
Dataset CHIRPS (Curah Hujan)	
latitude	Koordinat lintang pusat sel data berukuran sekitar $5,5 \times 5,5$ km
longitude	Koordinat bujur pusat sel data berukuran sekitar $5,5 \times 5,5$ km
date	Tanggal observasi (UTC+00:00)
precip	Total curah hujan harian (mm/hari)
Dataset ERA5 Land dari ECMWF(Temperatur dan Angin)	
latitude	Koordinat lintang pusat sel data berukuran sekitar 9×9 km
longitude	Koordinat bujur pusat sel data berukuran sekitar 9×9 km
date	Tanggal observasi (UTC+00:00)
t2m	Suhu udara rata-rata harian pada ketinggian 2 meter (Kelvin)
d2m	Suhu titik embun rata-rata harian pada ketinggian 2 meter (Kelvin)
u10	Kecepatan angin zonal (timur-barat) pada ketinggian 10 meter (m/s)
v10	Kecepatan angin meridional (utara-selatan) pada ketinggian 10 meter (m/s)

Tabel 1. Deskripsi Variabel Utama Data Hotspot dan Iklim

Untuk kelengkapan analisis, digunakan pula data batas administrasi kabupaten Indonesia sebagai data pendukung spasial. Data ini digunakan untuk mengubah hasil analisis dari skala titik dan grid menjadi informasi yang lebih operasional pada level wilayah administratif.

Dengan demikian, hasil prediksi tidak hanya menunjukkan pola risiko secara spasial, tetapi juga dapat mengidentifikasi kabupaten yang perlu diprioritaskan dalam mitigasi karhutla. Kombinasi data hotspot, iklim, dan batas administrasi memungkinkan model bergerak dari deteksi kejadian menuju identifikasi wilayah

risiko. Kerangka ini tidak hanya relevan untuk sistem peringatan dini di Indonesia, tetapi juga berpotensi diperluas sebagai pendekatan analisis risiko karhutla pada level ASEAN, khususnya dalam mitigasi kabut asap lintas batas.

2.1.2 Prapemrosesan Data

Pada prapemrosesan, seluruh dataset diseleksi berdasarkan cakupan Indonesia dan periode 2021–2025. Observasi di luar cakupan, data duplikat, nilai kosong atau tidak valid, serta atribut yang tidak digunakan dihapus untuk menjaga konsistensi sebelum integrasi antarsumber. Khusus FIRMS, deteksi berkepercayaan rendah dibuang untuk mengurangi *false positive*.

Penyamaan unit spasial dan temporal dilakukan karena setiap sumber data memiliki format yang berbeda. Data FIRMS tersedia sebagai titik deteksi hotspot berdasarkan koordinat lintang, bujur, dan tanggal kejadian, sedangkan CHIRPS dan ERA5-Land tersedia dalam format grid yang memuat observasi iklim harian. Agar ketiganya dapat digabungkan, seluruh data diseragamkan ke grid $0,25^\circ \times 0,25^\circ$ dengan resolusi temporal harian. Pada tahap ini, FIRMS diagregasi menjadi jumlah hotspot per grid-hari, sementara CHIRPS dan ERA5-Land disesuaikan ke grid dan tanggal yang sama sehingga setiap observasi memuat target hotspot dan variabel iklim pada lokasi serta tanggal yang identik.

Rekayasa fitur dilakukan untuk memperoleh variabel iklim yang lebih informatif. Suhu udara dan suhu titik embun dikonversi dari Kelvin ke Celsius. Kecepatan angin total dihitung dari komponen $u10$ dan $v10$ melalui $\sqrt{(u^2 + v^2)}$, sedangkan kelembapan relatif diestimasi dari suhu udara dan suhu titik embun menggunakan rumus Magnus.


Untuk model tahap pertama, dilakukan rekayasa fitur berbasis waktu dan riwayat iklim. Variabel waktu dikodekan secara siklik melalui sinus dan kosinus bulan serta hari dalam tahun, sementara variabel tahun menangkap variasi antartahun. Curah hujan diolah menjadi fitur akumulasi 7, 30, 60, dan 90 hari serta lag 1, 3, 7, dan 14 hari. Suhu, kelembapan relatif, dan kecepatan angin diolah menjadi fitur *rolling*: maksimum suhu (7 dan 30 hari), minimum kelembapan (7 dan 30 hari), serta rata-rata kecepatan angin (7 hari). Fitur-fitur tersebut menjadi input model tahap pertama untuk memprediksi hotspot pada level grid-harian, yang kemudian digunakan sebagai dasar pemodelan tahap kedua.

Untuk persiapan tahap kedua, prediksi grid-harian dari Stage 1 diagregasi ke level kabupaten-bulanan melalui *spatial join* antara koordinat grid dan batas administrasi kabupaten. Wilayah kota dikecualikan karena fokus studi pada kebakaran rural, sementara beberapa kabupaten kepulauan terisolasi yang tidak terpotret grid $0,25^\circ$ dipasangkan manual dengan grid terdekat. Setelah validasi geometri, analisis akhir mencakup 413 kabupaten. Struktur ketetanggaan antarkabupaten dibentuk berdasarkan kontiguitas geografis untuk

merepresentasikan hubungan spasial dalam model Bayesian, sehingga prediksi risiko mempertimbangkan baik kondisi iklim maupun kedekatan geografis.

2.1.3 Pemodelan


Analisis dilakukan dengan metode Two-Stage Hierarchical Model, kerangka pemodelan dua tahap yang menggabungkan keunggulan machine learning dan model Bayesian spasial-temporal. Tahap pertama menggunakan Extreme Gradient Boosting (XGBoost) untuk menghasilkan prediksi awal jumlah hotspot pada level grid-harian. Tahap kedua menggunakan Bayesian berbasis Integrated Nested Laplace Approximation (INLA) sebagai model utama yang mengubah prediksi model XGBoost menjadi estimasi risiko bulanan pada level kabupaten. Dengan rancangan ini, XGBoost berperan menangkap sinyal iklim non-linear, sedangkan Bayesian INLA menambahkan struktur spasial, temporal, dan ketidakpastian prediksi. Diagram alir lengkapnya sebagai berikut.



Gambar 2. Diagram Alir Pemodelan

2.1.3.1 Pemodelan Tahap Pertama menggunakan XGBoost

Pada tahap pertama, XGBoost memprediksi jumlah hotspot per grid-hari berdasarkan variabel iklim, fitur waktu, dan riwayat. Karena target sangat zero-inflated, digunakan fungsi objektif Tweedie (parameter variansi 1,5)—campuran Poisson-Gamma yang cocok untuk data semi-kontinu nonnegatif. XGBoost membangun pohon keputusan secara bertahap: setiap pohon dilatih untuk memprediksi residu dari prediksi gabungan pohon sebelumnya, dan prediksi akhir adalah jumlah kontribusi seluruh pohon. Mekanisme ini memungkinkan XGBoost menangkap pola nonlinier antara faktor iklim dan kemunculan hotspot (Gambar 2).



Gambar . Alur Kerja XGBoost

Dalam analisis ini, model dilatih dengan target berupa jumlah hotspot aktual pada setiap grid-hari. Selama proses pelatihan, XGBoost membentuk pola pemisahan pada pohon keputusan berdasarkan kombinasi variabel iklim, fitur waktu, dan fitur historis yang paling informatif terhadap kemunculan hotspot. Hasil dari tahap ini adalah prediksi jumlah hotspot untuk setiap kombinasi grid dan tanggal. Untuk memastikan model dapat memprediksi periode masa depan, data dipecah secara temporal: 2021–2023 sebagai data latih, 2024 sebagai validasi untuk penyetelan hiperparameter dengan early stopping, dan 2025 sebagai data uji yang sepenuhnya disembunyikan.

Prediksi XGBoost kemudian digunakan sebagai sinyal awal risiko berbasis iklim yang akan diintegrasikan ke level kabupaten-bulanan dan digunakan sebagai variabel penjelas utama dalam model Bayesian INLA.

2.1.3.2 Pemodelan Tahap Kedua menggunakan INLA

Pada pemodelan tahap kedua, digunakan model Bayesian berbasis Integrated Nested Laplace Approximation (INLA) untuk mengestimasi risiko



hotspot pada level kabupaten-bulanan. INLA berperan sebagai model utama karena mampu menggabungkan sinyal risiko berbasis iklim dari XGBoost dengan struktur spasial antarwilayah, dinamika temporal bulanan, dan ketidakpastian prediksi. Variabel yang diprediksi dalam tahap ini adalah jumlah hotspot aktual pada setiap kabupaten-bulan. Karena variabel tersebut berupa data cacahan yang sangat over-dispersed (rasio variansi terhadap rata-rata jauh lebih besar dari satu), digunakan distribusi Negative Binomial yang dapat mengakomodasi variansi melebihi rata-rata, tidak seperti distribusi Poisson.

Pemodelan INLA dimulai dengan model baseline yang hanya memuat intercept dan efek spasial. Efek spasial dimodelkan menggunakan Besag-York-Mollié 2 (BYM2), kombinasi dua komponen: spatial structured yang menangkap kemiripan risiko antarkabupaten yang berdekatan secara geografis, dan spatial unstructured yang menangkap variasi laten tiap kabupaten yang tidak dijelaskan oleh tetangganya. Model baseline ini digunakan sebagai pembanding awal untuk melihat pola risiko yang dapat dijelaskan oleh struktur spasial saja.

Setelah baseline terbentuk, prediksi XGBoost yang telah diagregasi ke level kabupaten-bulanan dimasukkan sebagai variabel penjelas utama. Prediksi tersebut kemudian ditransformasi dengan logaritma dan distandardisasi agar lebih stabil dalam proses estimasi.

Selanjutnya, model diperluas dengan efek temporal random walk orde pertama (RW1) untuk menangkap perubahan risiko dari bulan ke bulan yang belum seluruhnya tertangkap oleh prediksi XGBoost. Dengan demikian, model akhir menggabungkan prediksi XGBoost sebagai sinyal iklim, efek spasial BYM2, efek temporal RW1, dan distribusi Negative Binomial untuk menghasilkan estimasi risiko hotspot kabupaten-bulanan. Keluaran model ini berupa estimasi jumlah hotspot, peta risiko, serta probabilitas suatu wilayah melewati ambang batas risiko tertentu.

2.1.4 Evaluasi Model

Evaluasi model dilakukan dengan membandingkan tiga model nested: baseline spasial, Stage 2 dengan prediksi XGBoost, dan Stage 2 dengan tambahan efek temporal RW1. Perbandingan menggunakan DIC dan WAIC, dengan nilai yang lebih rendah menunjukkan model yang lebih baik. Evaluasi ini bertujuan menilai apakah penambahan sinyal iklim dari XGBoost dan efek temporal mampu meningkatkan kualitas model Bayesian.


Selain itu, model akhir dievaluasi melalui dekomposisi variansi untuk melihat kontribusi relatif prediksi XGBoost, efek spasial, dan efek temporal terhadap risiko hotspot. Kemampuan prediksi diuji menggunakan MAE dan korelasi

Spearman pada data latih serta validasi out-of-sample tahun 2025. MAE mengukur rata-rata kesalahan prediksi, sedangkan Spearman menilai kemampuan model dalam mengurutkan wilayah berdasarkan tingkat risiko.


2.2 Hasil dan Pembahasan

2.2.1 Karakteristik Risiko Kebakaran Hutan dan Lahan Indonesia

Terdapat tiga karakteristik data kebakaran hutan dan lahan (karhutla) Indonesia 2021–2025 yang menentukan pilihan metodologi statistik. Pertama, terdapat heterogenitas *temporal* ekstrem pada jumlah kejadian kebakaran. Total hotspot bulanan se-Indonesia berkisar dari ~2 ribu hingga ~74 ribu, dipicu modulasi El Niño-Southern Oscillation (Gambar 3). Kedua, terdapat heterogenitas *spasial* respons iklim. Setiap wilayah merespons kekeringan dengan pola waktu yang berbeda. Di Riau, peningkatan hotspot baru terlihat kuat sekitar 90 hari setelah penurunan curah hujan, sedangkan di Jawa Tengah, respons terjadi hampir langsung (Gambar). Perbedaan ini kemungkinan dipengaruhi oleh kombinasi karakteristik lahan, tipe vegetasi, serta kapasitas masing-masing wilayah dalam menyimpan kelembapan setelah hujan. Ketiga, terdapat *over-dispersion* (persebaran) ekstrem pada jumlah hotspot. Rasio variansi terhadap rata-rata total hotspot se-Indonesia mencapai 820, menjadi bukti empiris kuat untuk Negative Binomial Likelihood.



Gambar 3. Total Hotspot Bulanan Indonesia Sepanjang Waktu



Gambar 4. Perbandingan Window Akumulasi Curah Hujan Optimal Beberapa Provinsi

2.2.2 Performa Model dan Dekomposisi Variansi

Performa model dievaluasi melalui tiga model nested yang dibangun secara bertahap. Model baseline hanya berisi intercept dan spatial random effect BYM2 (kombinasi efek spasial terstruktur berdasarkan kedekatan antarkabupaten dan efek acak spesifik tiap kabupaten), tanpa informasi iklim apa pun. Didapatkan WAIC baseline sebesar 136.412.

Model Stage 2 menambahkan standardisasi dari $\log_pred_std$, yaitu log prediksi XGBoost ke baseline. Penambahan satu kovariat ini menurunkan WAIC secara signifikan menjadi 114.178, menunjukkan kontribusi prediktif Stage 1 sangat penting. Setiap kenaikan satu standar deviasi pada sinyal iklim hasil Stage 1 berkaitan dengan peningkatan ekspektasi jumlah hotspot sekitar $\exp(1,617) \approx 5,04$ kali lipat.

Model akhir (Stage 2 + Temporal RW1) menambahkan temporal random effect RW1 untuk dimensi waktu. WAIC turun lagi menjadi 113.844. Meski tambahannya kecil di metrik WAIC, komponen temporal ini krusial untuk menangkap dinamika ENSO yang akan didiskusikan di subbab 3.4.

Tabel 2. Perbandingan Performa Ketiga Model

Model	DIC	WAIC	Δ WAIC vs Baseline
Baseline (intercept + spatial)	136.048	136.412	
Stage 2 (+ XGBoost)	114.017	114.178	-22.234
Stage 2 + Temporal RW1 (final)	113.500	113.844	-22.567

Dekomposisi total variansi prediktor di skala log ke empat komponen (Tabel 3) menjelaskan sumber risiko kebakaran. 80,1% dijelaskan kovariat iklim yang dipelajari XGBoost; 14,2% dari heterogenitas spasial unstructured (karakteristik laten per kabupaten yang tidak dijelaskan iklim maupun kabupaten tetangga); 4,7% dari karakteristik temporal RW1; dan hanya 1,0% spasial structured dari BYM2.

Tabel 3. Dekomposisi Variansi Linear Prediktor Pada Model Akhir

Komponen	Nilai (σ^2)	Persentase
Kovariat (XGBoost)	2,544	80,1%
Spatial Unstructured	0,453	14,2%
Temporal (RW1)	0,149	4,7%
Spatial Structured (BYM2)	0,030	1,0%
Total	3,176	100%

Hasil fit model pada data latih menunjukkan performa yang sangat tinggi, dengan MAE sebesar 2,4 dan korelasi Spearman ρ antara data prediksi dan aktual sebesar 0,989. Model kemudian di-fit kembali pada data tahun 2021–2024, lalu memprediksi 2025 sebagai validasi. Hasil validasi memberikan MAE 2,7 dan korelasi Spearman 0,948. Hasil evaluasi yang baik mendukung bahwa model memiliki performa prediksi yang baik dan mampu merepresentasikan pola karhutla dengan cukup akurat.

Tabel 4. Metrik Evaluasi Train dan Validasi Model

Model	Evaluasi	MAE global	Spearman global	Spearman per Kabupaten
Baseline (intercept + spatial)	Train	8,9021	0,612	0,500
	Validasi	8,4811	0,601	0,479
Stage 2 (+ XGBoost)	Train	2,9020	0,809	0,760
	Validasi	3,8901	0,735	0,690
Stage 2 + Temporal RW1 (final)	Train	2,4123	0,989	0,992
	Validasi	2,7431	0,948	0,832


2.2.4 Penerapan Model dengan WaspadaApi

Model akhir digunakan untuk menjawab tiga pertanyaan operasional yang memotivasi studi ini. Seluruh jawaban dilampirkan melalui WaspadaApi, dashboard Shiny interaktif yang memungkinkan eksplorasi 413 kabupaten $\times$ 72




bulan (Januari 2021 – Desember 2026). Dashboard ini mengubah model dari justifikasi akademik menjadi alat pengambilan keputusan yang dapat diakses publik dan pembuat kebijakan. Dashboard dapat diakses melalui tautan [berikut](#).

Pertanyaan pertama yang dapat dijawab WaspadaApi adalah, “Berapa risiko karhutla di kabupaten X bulan depan?” Jawaban disediakan pada halaman Forecast per Kabupaten dalam bentuk perkiraan jumlah hotspot lengkap dengan rentang ketidakpastian (bukan angka tunggal). Kabupaten dengan perkiraan jumlah hotspot terbanyak pada 2026 juga ditampilkan pada halaman Beranda, beserta perkiraan untuk empat kabupaten dengan tipologi lanskap yang berbeda.




Gambar 5. Halaman Forecast Kabupaten




Gambar 6 . Halaman Beranda

Pertanyaan kedua yang dijawab WaspadaApi adalah, “Kabupaten mana yang berpotensi tinggi melebihi ambang krisis pada bulan X?”, yang dijawab pada halaman Peta Risiko. Probabilitas eksedansi $P(Y > 50)$ dihitung dari distribusi posterior prediktif sebagai metrik krisis. Sepuluh kabupaten dengan peluang tertinggi melebihi ambang ini di puncak 2026 didominasi Kalimantan Barat, Nusa Tenggara Timur, dan Papua Selatan, seperti Kabupaten Merauke (September, $P = 0,993$; median 864 hotspot), Sanggau (Agustus, $P = 0,992$), dan Kupang (Oktober, $P = 0,988$). Ukuran probabilitas seperti ini tepat untuk peringatan dini, karena setiap angka dapat ditranslasikan ke tingkat siaga dan alokasi sumber daya secara proporsional.



Gambar 7. Halaman Peta Risiko

Terakhir, halaman Sumber Risiko menjawab “Apa yang lebih menyebabkan suatu kabupaten ‘berisiko’?” Pertanyaan ini sudah terjawab via dekomposisi variansi di subbab 3.2 (80,1% iklim, 14,2% spasial laten, 4,7% temporal, 1,0% spasial structured). Pemecahan ini berfungsi sebagai instrumen prioritas kebijakan. Risiko tinggi yang dijelaskan iklim dapat ditindaklanjuti via investasi pemantauan iklim *real-time*, sedangkan sedikit yang berasal dari faktor laten geografis menuntut intervensi struktural berbeda seperti pemetaan gambut, kebijakan tutupan lahan, dan praktik pengelolaan lokal. Dengan kata lain, dekomposisi ini memisahkan komponen risiko yang dapat dikurangi melalui deteksi dari yang dapat dikurangi hanya melalui intervensi struktural.



Gambar 8. Halaman Sumber Risiko

3. KESIMPULAN DAN SARAN

Studi ini menjawab kebutuhan akan sistem prioritas risiko karhutla yang lebih tajam dari sekadar pemantauan titik panas. Pendekatan two-stage hierarchical yang menggabungkan XGBoost dan Bayesian INLA menghasilkan estimasi risiko probabilistik per kabupaten-bulan. Model mencapai korelasi Spearman 0,948 dan MAE 2,7 hotspot per kabupaten, dengan interval prediksi mencapai 93,4%. Lebih dari sekadar metrik agregat, dekomposisi variansi memisahkan komponen risiko yang dapat dimitigasi melalui pemantauan iklim (80,1%) dari komponen yang menuntut intervensi struktural seperti pemetaan gambut dan tata kelola lahan (14,2%). Pemecahan ini dapat langsung diterjemahkan ke pemrioritasan anggaran. Hasil ini disampaikan melalui WaspadaApi, dashboard publik yang memetakan 413 kabupaten Indonesia $\times$ 72 bulan, sehingga model tidak hanya teoretis, tetapi dapat menjadi alat pengambilan keputusan yang dapat diakses publik dan pembuat kebijakan.

Bagi peneliti, ada dua arah pengembangan utama dari model: (1) integrasi seasonal forecast (NMME, ECMWF SEAS5) untuk meningkatkan akurasi forecast, dan (2) integrasi data jenis lahan untuk menguraikan komponen 14,2% spatial unstructured yang saat ini masih laten. Pendekatan two-stage ini juga berpotensi diaplikasikan ke fenomena lain dengan struktur serupa, seperti banjir, longsor, penyakit, selama yang memiliki pendorong iklim nonlinear dan heterogenitas spasial signifikan. Bagi pembuat kebijakan, dashboard ini dapat segera dipakai untuk perencanaan patroli, pembasahan gambut, dan koordinasi sumber daya menjelang puncak musim 2026, khususnya di Kalimantan Barat, Nusa Tenggara Timur, dan Papua Selatan yang konsisten muncul sebagai wilayah berisiko tertinggi. Dalam



konteks ASEAN, sistem ini berpotensi diintegrasikan dengan ASMC Alert Level untuk mendorong aksi dini di wilayah sumber sebelum kabut asap lintas batas terjadi.



DAFTAR PUSTAKA

- ASEAN. (2002) ASEAN Agreement on Transboundary Haze Pollution. Jakarta: Association of Southeast Asian Nations. Available at: <https://asean.org/wp-content/uploads/2021/01/ASEANAgreementonTransboundaryHazePollution-1.pdf> (Accessed: 20 April 2026).
- ASEAN Specialised Meteorological Centre (ASMC). (2025) Review of Regional Haze Situation for July 2025. Available at: <https://asmc.asean.org/review-of-regional-haze-situation-for-july-2025/> (Accessed: 24 April 2026).
- Badan Meteorologi, Klimatologi, dan Geofisika (BMKG). (2026) Citra Polar Hotspot. Available at: <https://www.bmkg.go.id/cuaca/satelit/polar-hotspot> (Accessed: 24 April 2026).
- Balmaseda, M.A., Johnson, S.J., Ferranti, L., Molteni, F., Magnusson, L., Tietsche, S., Decremmer, D., Weisheimer, A., Balsamo, G., Keeley, S.P.E., Mogensen, K., Zuo, H. and Monge-Sanz, B.M. (2019) 'SEAS5: the new ECMWF seasonal forecast system', *Geoscientific Model Development*, 12, pp. 1087-1117. doi: 10.5194/gmd-12-1087-2019.
- Chang, W., Cheng, J., Allaire, J.J., Sievert, C., Schloerke, B., Aden-Buie, G., Xie, Y., Allen, J., McPherson, J., Dipert, A. and Borges, B. (2026) shiny: Web Application Framework for R. R package. Available at: <https://shiny.posit.co/> (Accessed: 24 April 2026).
- Chen, T. and Guestrin, C. (2016) 'XGBoost: A scalable tree boosting system', in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM, pp. 785-794. doi: 10.1145/2939672.2939785.
- Copernicus Climate Change Service (C3S). (2026) ERA5-Land hourly data from 1950 to present. Available at: <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-land> (Accessed: 24 April 2026).
- Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A. and Michaelsen, J. (2015) 'The climate hazards infrared precipitation with stations-a new environmental record for monitoring extremes', *Scientific Data*, 2, 150066. doi: 10.1038/sdata.2015.66.
- GADM. (2026) GADM Database of Global Administrative Areas, version 4.1. Available at: <https://gadm.org/> (Accessed: 24 April 2026).
- Kementerian Lingkungan Hidup dan Kehutanan (KLHK). (2026) SiPongi+: Sistem Pemantauan Karhutla. Available at: <https://sipongi.gakkum.kehutan.go.id/> (Accessed: 24 April 2026).



- Kirtman, B.P., Min, D., Infanti, J.M., Kinter, J.L., Paolino, D.A., Zhang, Q., van den Dool, H., Saha, S., Mendez, M.P., Becker, E., Peng, P., Tripp, P., Huang, J., DeWitt, D.G., Tippet, M.K., Barnston, A.G., Li, S., Rosati, A., Schubert, S.D., Rienecker, M., Suarez, M., Li, Z.E., Marshak, J., Lim, Y.K., Tribbia, J., Pegion, K., Merryfield, W.J., Denis, B. and Wood, E.F. (2014) 'The North American Multimodel Ensemble: Phase-1 seasonal-to-interannual prediction; Phase-2 toward developing intraseasonal prediction', *Bulletin of the American Meteorological Society*, 95(4), pp. 585-601. doi: 10.1175/BAMS-D-12-00050.1.
- Kopplitz, S.N., Mickley, L.J., Marlier, M.E., Buonocore, J.J., Kim, P.S., Liu, T., Sulprizio, M.P., DeFries, R.S., Jacob, D.J., Schwartz, J., Pongsiri, M. and Myers, S.S. (2016) 'Public health impacts of the severe haze in Equatorial Asia in September-October 2015: demonstration of a new framework for informing fire management strategies to reduce downwind smoke exposure', *Environmental Research Letters*, 11(9), 094023. doi: 10.1088/1748-9326/11/9/094023.
- Muñoz-Sabater, J., Dutra, E., Agustí-Panareda, A., Albergel, C., Arduini, G., Balsamo, G., Boussetta, S., Choulga, M., Harrigan, S., Hersbach, H., Martens, B., Miralles, D.G., Piles, M., Rodríguez-Fernández, N.J., Zsoter, E., Buontempo, C. and Thépaut, J.N. (2021) 'ERA5-Land: a state-of-the-art global reanalysis dataset for land applications', *Earth System Science Data*, 13, pp. 4349-4383. doi: 10.5194/essd-13-4349-2021.
- NASA Fire Information for Resource Management System (FIRMS). (2026) VIIRS I-Band 375 m Active Fire Data. Available at: <https://www.earthdata.nasa.gov/data/instruments/viirs/viirs-i-band-375-m-active-fire-data> (Accessed: 24 April 2026).
- Riebler, A., Sørbye, S.H., Simpson, D. and Rue, H. (2016) 'An intuitive Bayesian spatial model for disease mapping that accounts for scaling', *Statistical Methods in Medical Research*, 25(4), pp. 1145-1165. doi: 10.1177/0962280216660421.
- Rue, H., Martino, S. and Chopin, N. (2009) 'Approximate Bayesian inference for latent Gaussian models by using integrated nested Laplace approximations', *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 71(2), pp. 319-392. doi: 10.1111/j.1467-9868.2008.00700.x.
- Spearman, C. (1904) 'The proof and measurement of association between two things', *The American Journal of Psychology*, 15(1), pp. 72-101. doi: 10.2307/1412159.
- Spiegelhalter, D.J., Best, N.G., Carlin, B.P. and van der Linde, A. (2002) 'Bayesian measures of model complexity and fit', *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 64(4), pp. 583-639. doi: 10.1111/1467-9868.00353.



Watanabe, S. (2010) 'Asymptotic equivalence of Bayes cross validation and widely applicable information criterion in singular learning theory', *Journal of Machine Learning Research*, 11, pp. 3571-3594.

World Bank. (2016) *The Cost of Fire: An Economic Analysis of Indonesia's 2015 Fire Crisis*. Washington, DC: World Bank. Available at: <https://documents.worldbank.org/en/publication/documents-reports/documentdetail/776101467990969768> (Accessed: 24 April 2026).